

Prediccion de Resistencia Antimicrobiana desde Genomas Completos Usando Redes Neuronales

Autor 1, Autor 2, Autor 3 y Autor 4

La resistencia antimicrobiana (RAM) es un problema clinico critico porque clasificar una bacteria resistente como susceptible puede llevar a un tratamiento inefectivo. Este proyecto evalua modelos de redes neuronales para predecir RAM binaria a partir de secuenciacion del genoma completo (WGS, por *Whole-Genome Sequencing*), es decir, la lectura de la secuencia de ADN completa o casi completa de una bacteria. Usamos archivos FASTA, un formato de texto para almacenar secuencias de ADN, y etiquetas fenotipicas publicas de BV-BRC. Cada muestra es un par genoma-antibiotico y el antibiotico entra al modelo como un embedding aprendido. Primero se construyo un benchmark ESKAPE y se compararon un perceptron multicapa, modelos BiGRU y modelos jerarquicos basados en histogramas locales de k-meros. El mejor modelo ESKAPE fue HierSet, un encoder de conjunto invariante a permutaciones sobre 256 segmentos de histogramas $k=4$ con atencion condicionada por antibiotico. En el benchmark ESKAPE obtuvo $F1=0.8900$, $recall=0.9088$ y $AUC=0.9368$; con un umbral clinico de 0.40 alcanzo $recall=0.9289$ con una caida pequena de $F1$. Luego se expandio el dataset mas alla de ESKAPE, manteniendo congelado el test ESKAPE original. El dataset expandido mejoro el test ESKAPE congelado cuando se recalibro `pos_weight_scale` a 1.0: $F1=0.8973$, $recall=0.9261$ y $AUC=0.9463$. Sin embargo, el rendimiento en nuevos taxones siguio siendo menor ($F1=0.7539$). La conclusion principal es que HierSet es la mejor arquitectura probada y que mas datos pueden mejorar el benchmark ESKAPE si se ajusta correctamente el manejo del desbalance. La generalizacion multi-taxon sigue limitada por shift de distribucion, confounding taxonomico y calibracion.

Index Terms—Resistencia antimicrobiana, aprendizaje profundo, k-meros, redes neuronales, secuenciacion genomica completa.

I. OBJETIVO Y ALCANCE

EL objetivo del proyecto es predecir si un genoma bacteriano es resistente o susceptible a un antibiotico dado usando features derivadas de WGS y redes neuronales. En este informe, WGS significa secuenciacion del genoma completo: no se analiza solo un gen aislado, sino la composicion de la secuencia de ADN disponible para todo el genoma bacteriano. Cada registro corresponde a un par (`genome_id`, `antibiotic`) con una etiqueta binaria: resistente o susceptible.

El alcance inicial fue un benchmark sobre organismos ESKAPE usando datos de BV-BRC [1]. Despues se agrego un experimento expandido all-taxa para evaluar si mas datos publicos de RAM mejoran la generalizacion sin contaminar el test ESKAPE original.

El proyecto compara tres familias de modelos: un baseline superficial MLP sobre histogramas globales de k-meros, modelos recurrentes BiGRU con atencion y modelos jerarquicos tipo conjunto. La arquitectura seleccionada es HierSet porque obtiene el mejor $F1/AUC$ en ESKAPE y tambien es la mas fuerte en los experimentos expandidos.

II. CONTEXTO Y FUNDAMENTOS

La prediccion de RAM desde genomas completos es un problema de clasificacion supervisada con relevancia clinica y epidemiologica [2]–[4]. El modelo debe aprender relaciones entre contenido genomico y susceptibilidad antimicrobiana. El genoma puede contener genes de resistencia, mutaciones puntuales, elementos moviles y senales taxonomicas. Como los genomas son largos y variables, la representacion de entrada es decisiva.

Redes Neuronales, 2026-I. Informe final del proyecto. Pendiente: reemplazar con nombres, equipo, afiliaciones y metadatos de entrega.

Los histogramas de k-meros son una representacion practica porque resumen composicion de ADN sin requerir alineamiento ni anotacion genetica [5]. Un k-mero es una subsecuencia de ADN de longitud k ; por ejemplo, si $k = 4$, ATGC es un k-mero. Un histograma de k-meros cuenta con que frecuencia aparece cada posible subsecuencia. En este proyecto se usaron histogramas globales $k=3,4,5$ para MLP y BiGRU, e histogramas segmentados $k=4$ para HierSet. Los modelos se entrenaron con principios estandar de aprendizaje profundo, incluyendo regularizacion, optimizacion con AdamW, seleccion de umbral en validacion y early stopping [6]–[9].

Se probaron redes recurrentes bidireccionales y mecanismos de atencion porque algunos enfoques tratan representaciones genomicas como secuencias [10]–[13]. Sin embargo, nuestros resultados muestran que tratar bins de histogramas o segmentos genomicos como secuencias puede introducir supuestos de orden artificiales. HierSet elimina ese sesgo al tratar los segmentos como un conjunto y usar atencion condicionada por antibiotico.

III. CASO DE ESTUDIO

BV-BRC integra recursos bacterianos y virales, incluyendo genomas, metadatos y fenotipos de susceptibilidad antimicrobiana [1]. Este proyecto usa BV-BRC como caso de estudio porque permite construir pares genoma-antibiotico a escala, descargar secuencias FASTA y comparar modelos sobre un benchmark reproducible.

La pregunta practica es si una red neuronal puede aprender una funcion $f(g, a)$ que, dado un genoma g y un antibiotico a , prediga resistencia binaria. La dificultad no esta solo en entrenar una red, sino en evitar leakage por genoma, controlar desbalance, separar especies conocidas de nuevos taxones y distinguir senal biologica de shortcuts taxonomicos.

IV. DATOS

Los datos provienen de BV-BRC. Las etiquetas fenotípicas AMR se descargaron desde `genome_amr` y las secuencias genómicas desde endpoints de genomas. El benchmark original incluyó organismos ESKAPE, excepto *Enterobacter spp.*, que no apareció de forma limpia en el endpoint AMR usado. El dataset raw ESKAPE inicial tenía 162,170 registros, 16,281 genomas únicos, 96 antibióticos y 5 taxones ESKAPE.

El dataset expandido all-taxa tuvo 383,068 registros raw, 44,905 genomas, 581 taxones y 125 antibióticos. Después de limpieza previa para descarga, quedaron 282,997 registros, 37,892 genomas, 581 taxones y 100 antibióticos. El dataset efectivo después del filtro genómico tuvo 282,716 registros y 37,678 genomas.

V. LIMPIEZA Y EDA

A. Reglas de Limpieza

Las reglas finales se derivaron del EDA. Se conservaron solo evidencias de laboratorio, fenotipos binarios *Resistant* y *Susceptible*, y método *Broth dilution*. Luego se eliminaron pares contradictorios (`genome_id`, `antibiotic`) con etiquetas R y S simultáneas, se deduplicaron pares consistentes, se conservaron antibióticos con al menos 20 registros útiles, se exigió FASTA disponible y se filtraron genomas menores a 0.5 Mb.

En el dataset expandido, la limpieza removió 75,465 registros con método distinto a *Broth dilution*, 1,833 pares contradictorios equivalentes a 3,809 filas, 20,749 duplicados consistentes, 8 antibióticos de baja frecuencia equivalentes a 48 filas, y 214 genomas por longitud menor a 0.5 Mb.

B. Hallazgos en ESKAPE

El benchmark ESKAPE original tenía un balance global cercano a 54% resistente y 46% susceptible. Sin embargo, el balance variaba mucho por especie y antibiótico. Por ejemplo, *A. baumannii* era mayoritariamente resistente, mientras *S. aureus* era mayoritariamente susceptible. Esto crea un riesgo de confounding: los k-meros codifican identidad taxonómica, por lo que el modelo podría aprender priors por especie en vez de mecanismos de resistencia.

El baseline sin información genómica fue la clase mayoritaria por antibiótico, con $\text{accuracy}=71.2\%$, $\text{precision}=0.7281$, $\text{recall}=0.7453$ y $\text{F1}=0.7366$. El criterio de éxito del proyecto fue superar $\text{F1}=0.85$ con recall clínicamente útil.

C. Hallazgos en el Dataset Expandido

El dataset expandido cambió fuertemente la distribución: 101,350 registros resistentes y 181,366 susceptibles, balance global de 35.8% resistente y 64.2% susceptible, $\text{pos_weight}=1.7890$ en train, subset *locked* ESKAPE con 61.3% resistente y subset *new* con 25.4% resistente. Este shift es fuerte: los nuevos taxones son mucho más susceptibles que el benchmark ESKAPE congelado. Por eso, la configuración de desbalance que funcionaba en ESKAPE no transfiere directamente.

El dataset expandido también tiene una cola taxonómica larga: 581 taxones, mediana de 9 registros por taxon, percentil 75 de 16 registros y un taxon mayor con 52,154 registros. Los antibióticos más frecuentes también cambiaron; aparecen isoniazid, ethambutol y pyrazinamide, lo que confirma que el dataset expandido no es simplemente más ESKAPE, sino un problema multi-organismo más heterogéneo.

VI. INGENIERIA DE FEATURES

A. Histogramas Globales de K-meros

El MLP usó histogramas concatenados $k=3,4,5$: 64 bins para $k=3$, 256 bins para $k=4$ y 1024 bins para $k=5$, para un total de 1344 dimensiones. Las features se normalizaron usando media y desviación estándar del train set para evitar leakage.

B. Representación BiGRU

La BiGRU reutilizó los histogramas $k=3,4,5$, relleno cada histograma hasta 1024 bins y apiló los tres k como columnas, siguiendo la representación distribuida de k-meros propuesta para identificación bacteriana con RNN [13]. Esto produce una matriz $[1024, 3]$. La representación permite usar una BiGRU, pero impone un orden pseudo-secuencial sobre bins que no son biológicamente secuenciales.

C. Representación Jerárquica Segmentada

La representación jerárquica divide cada genoma en 256 segmentos contiguos y calcula un histograma $k=4$ por segmento. El resultado es una matriz $[256, 256]$ por genoma. Esto preserva localidad genómica gruesa y cobertura completa.

La motivación principal para explorar esta arquitectura fue que la señal asociada a resistencia puede ocupar una fracción muy pequeña del genoma completo. Si el modelo recibe solo un histograma global, esa señal puede quedar diluida dentro de millones de bases. Al partir el genoma en secciones, el modelo evalúa regiones más pequeñas y puede aprender a asignar mayor peso a segmentos donde aparezcan patrones relevantes para un antibiótico. HierSet trata estos segmentos como un conjunto, una decisión importante porque los genes de resistencia y elementos móviles no aparecen en posiciones fijas del genoma.

VII. MODELOS PROPUESTOS

A. MLP

El MLP recibe el vector normalizado de 1344 dimensiones, lo concatena con el embedding del antibiótico y usa dos capas ocultas con dropout. En ESKAPE obtuvo $\text{F1}=0.8600$, $\text{recall}=0.9165$ y $\text{AUC}=0.9035$. Esto confirmó que la composición global de k-meros contiene señal fuerte para RAM.

B. BiGRU con Atención

La BiGRU procesa la matriz $[1024, 3]$ con una GRU bidireccional y atención de Bahdanau [10]–[12]. Luego concatena el contexto con el embedding del antibiótico. Su mejor resultado ESKAPE fue $\text{F1}=0.8566$, $\text{recall}=0.9032$ y $\text{AUC}=0.8998$. Cumple el criterio de recall, pero no supera al MLP. La causa probable es que el modelo trata el orden de bins como una secuencia aunque no tenga significado biológico directo.

C. MultiBiGRU y HierBiGRU

MultiBiGRU procesa $k=3,4,5$ en streams separados usando un encoder sin dependencias secuenciales entre bins. Luego fusiona los streams con gates condicionados por antibiotico. Obtuvo $F1=0.8514$, $recall=0.8925$ y $AUC=0.8944$. Fue interpretable, pero no competitivo frente a HierSet.

HierBiGRU procesa la representacion segmentada $[256, 256]$ como una secuencia de segmentos. Obtuvo $F1=0.8307$, $recall=0.8788$ y $AUC=0.8539$. Fue un resultado negativo: segmentar el genoma no basta si el modelo impone un sesgo secuencial incorrecto.

D. HierSet

HierSet es el mejor modelo. Trata los 256 segmentos como un conjunto y usa cross-attention condicionada por antibiotico, inspirada en la atencion por producto punto escalado [14]:

$$\text{score}(s, a) = \frac{h_s \cdot q_a}{\sqrt{D}}. \quad (1)$$

Esto permite atender cualquier segmento sin asumir adyacencia o posicion fija. En ESKAPE obtuvo $F1=0.8900$, $recall=0.9088$, $precision=0.8720$ y $AUC=0.9368$. Con un umbral clinico $\theta = 0.40$ alcanzo $F1=0.8876$, $recall=0.9289$, $precision=0.8498$ y $AUC=0.9368$.

E. HierSet v2

HierSet v2 agrego multi-head attention e histogramas segmentados multi-escala $k=3,4,5$. Esto aumento la dimension por segmento de 256 a 1344. Obtuvo $F1=0.8895$, $recall=0.8971$ y $AUC=0.9366$. Fue un resultado negativo: no mejoro a HierSet v1 y redujo el recall.

VIII. PROTOCOLO DE ENTRENAMIENTO Y EVALUACION

El protocolo compartido uso split por `genome_id`, no por registro, para evitar leakage; split 70/15/15 train/validation/test; semilla 42; BCEWithLogitsLoss con `pos_weight` calculado sobre train; umbral seleccionado en validacion para maximizar F1; early stopping y checkpoint sobre F1 de validacion; gradient clipping en modelos recurrentes [15]; y metricas F1, recall, precision, AUC-ROC y accuracy.

Para experimentos expandidos, los splits ESKAPE originales se congelaron con `locked_splits`; los genomas nuevos se dividieron por separado; `splits.csv` incluye `split_source` con valores `locked` y `new`; y la evaluacion se reporto para `all`, `locked` y `new`.

IX. RESULTADOS

A. Benchmark ESKAPE

La Tabla I resume los resultados principales. HierSet fue el mejor modelo del proyecto en F1 y AUC, y el umbral clinico aumento recall con una perdida pequena de F1.

B. Dataset Expandido

El primer entrenamiento expandido reutilizo `pos_weight_scale=2.5` del setup ESKAPE. En test completo obtuvo $F1=0.8129$, $recall=0.8075$, $precision=0.8184$ y $AUC=0.9355$. En el subset `locked` obtuvo $F1=0.8874$, $recall=0.9039$ y $AUC=0.9384$; en `new`, $F1=0.7361$, $recall=0.7130$ y $AUC=0.9184$. Esto no mejoro claramente el test ESKAPE congelado y tuvo bajo F1/recall en nuevos taxones, aunque el AUC siguio siendo razonable.

El EDA expandido mostro que `pos_weight` de train subio a 1.7890. Multiplicarlo por 2.5 daba un peso efectivo de 4.4725, demasiado agresivo para un dataset donde `new` es mayoritariamente susceptible. Por eso se probaron `pos_weight_scale=1.0` y 1.5. La Tabla II muestra que 1.0 fue la mejor configuracion.

La mejor configuracion expandida fue HierSet entrenado sobre el dataset all-taxa con `pos_weight_scale=1.0`. Esta configuracion fue la mas equilibrada: mejoro el test ESKAPE congelado y tambien obtuvo el mejor F1 en los nuevos taxones frente a las variantes con `pos_weight_scale=1.5` y 2.5. Este fue el primer resultado claramente positivo del dataset expandido sobre el test ESKAPE congelado: F1 subio de 0.8900 a 0.8973, recall de 0.9088 a 0.9261 y AUC de 0.9368 a 0.9463. Sin embargo, `new` sigue por debajo de `locked`, por lo que el modelo no esta resuelto para generalizacion multi-taxon.

Como control, se entreno BiGRU expandido con `batch_size=128`, `pos_weight_scale=2.5` y `patience=15`. Obtuvo $F1=0.7683$, $recall=0.7830$ y $AUC=0.9009$ en test completo; $F1=0.8481$, $recall=0.8771$ y $AUC=0.8888$ en `locked`; y $F1=0.6878$, $recall=0.6908$ y $AUC=0.8847$ en `new`. BiGRU no se beneficio de la expansion y rindio peor que HierSet en todos los cortes.

X. DISCUSION

El hallazgo arquitectonico principal es que los supuestos de orden importan, pero tambien importa la escala a la que se busca la senal. La resistencia puede depender de genes, mutaciones o elementos moviles que representan una proporcion pequena del genoma. Los histogramas globales de k -meros ya son fuertes, pero pueden diluir senales locales. Procesarlos con modelos recurrentes puede agregar sesgos de orden artificiales. HierSet funciona mejor porque combina informacion local por segmentos con una atencion que no fuerza adyacencia ni posicion fija, lo que ayuda al modelo a buscar patrones relevantes en regiones mas pequenas del genoma.

El hallazgo de datos principal es que mas datos no garantizan mejor rendimiento. La expansion introdujo shifts fuertes en prior de clase, composicion taxonomica y distribucion de antibioticos. Cuando se recalibro `pos_weight_scale`, el entrenamiento expandido si mejoro el test ESKAPE congelado. Pero `new` siguio teniendo F1/recall bajos.

La diferencia entre AUC y F1 en `new` sugiere un problema de calibracion y umbral. El AUC razonable indica que el modelo rankea muchos resistentes por encima de susceptibles. El F1 bajo indica que un unico umbral global no transfiere bien entre `locked` y `new`, que tienen tasas base muy distintas.

TABLE I
RESULTADOS PRINCIPALES EN EL BENCHMARK ESKAPE.

Modelo	F1	Recall	Precision	AUC	Nota
MLP	0.8600	0.9165	0.8100	0.9035	Baseline fuerte
BiGRU + Attention	0.8566	0.9032	–	0.8998	Cumple recall
MultiBiGRU	0.8514	0.8925	–	0.8944	Recall borderline
HierBiGRU	0.8307	0.8788	–	0.8539	Resultado negativo
HierSet	0.8900	0.9088	0.8720	0.9368	Mejor ESKAPE
HierSet $\theta = 0.40$	0.8876	0.9289	0.8498	0.9368	Umbral clinico
HierSet v2	0.8895	0.8971	–	0.9366	No mejora v1

TABLE II
AJUSTE DE POS_WEIGHT_SCALE PARA HIERSET EN EL DATASET EXPANDIDO.

Scale	Subset	F1	Recall	Precision	AUC	Umbral
1.0	all	0.8273	0.8255	0.8290	0.9421	0.5274
1.0	locked	0.8973	0.9261	0.8702	0.9463	0.5274
1.0	new	0.7539	0.7271	0.7828	0.9260	0.5274
1.5	all	0.8152	0.8299	0.8009	0.9363	0.5675
1.5	locked	0.8883	0.9221	0.8568	0.9377	0.5675
1.5	new	0.7408	0.7397	0.7419	0.9197	0.5675
2.5	all	0.8129	0.8075	0.8184	0.9355	0.7302
2.5	locked	0.8874	0.9039	0.8716	0.9384	0.7302
2.5	new	0.7361	0.7130	0.7608	0.9184	0.7302

XI. CONSIDERACIONES ETICAS

La prediccion de RAM tiene riesgo clinico. Un falso negativo, predecir susceptible cuando la bacteria es resistente, puede llevar a tratamiento inefectivo. Por eso el recall es una metrica prioritaria. Un falso positivo tambien puede causar danos al empujar el uso innecesario de antibioticos de reserva.

El modelo no debe interpretarse como herramienta diagnostica clinica sin validacion externa. Las etiquetas provienen de bases publicas y pueden contener sesgo de muestreo, desbalance taxonomico, estandares de laboratorio heterogeneos y sobrerrepresentacion regional. Los experimentos expandidos muestran que el rendimiento varia por taxon y antibiotico.

Uso responsable requiere reportar metricas por subgrupo, mantener splits de test congelados, evitar afirmar generalizacion amplia sin validacion externa, documentar calibracion y umbrales, y usar predicciones como apoyo, no como reemplazo de pruebas de laboratorio.

XII. LIMITACIONES Y TRABAJO FUTURO

El modelo usa composicion de k-meros, no anotaciones explicitas de genes de resistencia, plasmidos, mutaciones o elementos moviles. El dataset expandido tiene cola taxonomica larga, con muchos taxones de bajo soporte. El conjunto de antibioticos cambia con la expansion, dificultando comparaciones directas. No se midio calibracion con ECE o reliability diagrams, no hubo validacion externa fuera de BV-BRC y no se aplicaron pruebas estadisticas formales sobre diferencias de metricas.

El trabajo futuro mas importante es agregar features biologicas explicitas desde CARD, ResFinder o AMRFinder-Plus; medir calibracion con ECE, Brier score y reliability diagrams; probar calibracion de umbral por `split_source`, antibiotico y taxones de alto soporte; evaluar en un dataset

externo fuera de BV-BRC; comparar contra baselines simples taxon-antibiotico para medir shortcuts taxonomicos; y explorar modelos hibridos que combinen k-meros y anotaciones de genes.

XIII. REPOSITORIO Y VIDEO

A.Codigo Fuente

Pendiente: URL final del repositorio. La organizacion principal del codigo esta en `src/bvbrc/` para descarga de datos, `src/data_pipeline/` para limpieza y features, `src/models/` para datasets y modelos, `src/train/` para entrenamiento y evaluacion, y `main.py` como CLI.

B.Video Explicativo

Pendiente: URL del video explicativo. El video deberia cubrir objetivo, datos, EDA, modelos, resultados ESKAPE, experimento expandido, limitaciones y conclusiones.

XIV. CONTRIBUCIONES DEL EQUIPO

Pendiente: nombres de integrantes y distribucion final de contribuciones. La Tabla III conserva la estructura sugerida.

XV. USO DE HERRAMIENTAS DE IA

Se usaron herramientas de IA para apoyar generacion de codigo, depuracion, refactorizacion, seguimiento experimental y redaccion del informe. La verificacion humana incluyo revisar diffs, ejecutar tests unitarios, correr entrenamientos y evaluaciones, y contrastar metricas contra artefactos guardados. Las conclusiones cientificas se basan en los experimentos ejecutados y documentados en el repositorio.

TABLE III
CONTRIBUCIONES DEL EQUIPO.

Integrante	Rol	Actividades
Por definir	Datos	Descarga e integracion BV-BRC
Por definir	EDA	Limpieza, analisis exploratorio y leakage
Por definir	Modelos	Feature engineering, entrenamiento y evaluacion
Por definir	Reporte	Redaccion, tablas, video y reproducibilidad

XVI. CONCLUSIONES

El mejor modelo del proyecto es HierSet, un encoder invariante a permutaciones sobre histogramas segmentados de k-meros, condicionado por el antibiotico. Su diseno responde a una hipotesis concreta: como la senal de resistencia puede ser local y ocupar una fraccion pequena del genoma, segmentar el genoma ayuda a que el modelo busque patrones en regiones mas pequenas en vez de depender solo de una composicion global diluida. En el benchmark ESKAPE obtuvo el mejor rendimiento general y, al usar un umbral conservador de 0.40 orientado a aumentar recall, alcanzo recall=0.9289 con perdida minima de F1. Este umbral no fue validado clinicamente; se uso como simulacion de una preferencia por reducir falsos negativos.

El experimento expandido cambio la conclusion de forma matizada. Reutilizar `pos_weight_scale=2.5` produjo resultados debiles. Al recalibrar `pos_weight_scale=1.0`, el dataset expandido mejoro las metricas sobre el test ESKAPE congelado. Esto sugiere que mas datos pueden ayudar, pero solo si el desbalance se reestima para la nueva distribucion.

Al mismo tiempo, el rendimiento en nuevos taxones sigue siendo sustancialmente menor. Por lo tanto, la afirmacion correcta no es que el proyecto resolvió RAM all-taxa. La afirmacion fuerte es que HierSet fue la mejor arquitectura probada, que los datos expandidos mejoran ESKAPE bajo ponderacion adecuada y que la generalizacion multi-taxon robusta sigue siendo un problema abierto.

AGRADECIMIENTOS

Se agradece a BV-BRC por disponibilizar recursos publicos de genomas bacterianos y fenotipos AMR. Pendiente: agregar agradecimientos del curso o institucion si aplica.

REFERENCES

- [1] R. D. Olson, R. Assaf, T. Brettin *et al.*, "Introducing the bacterial and viral bioinformatics resource center (bv-brc): a resource combining patric, ird and vipr," *Nucleic Acids Research*, vol. 51, no. D1, pp. D678–D689, 2023.
- [2] D. Boolchandani, E. D'Souza, and G. Dantas, "Sequencing-based methods and resources to study antimicrobial resistance," *Nature Reviews Genetics*, vol. 20, pp. 356–370, 2019.
- [3] C. U. Koser, M. J. Ellington, and S. R. Peacock, "Whole-genome sequencing to control antimicrobial resistance," *Trends in Genetics*, vol. 30, no. 9, pp. 401–407, 2014.
- [4] Y. Ren, T. Chakraborty, S. Doijad, L. Falgenhauer, J. Falgenhauer, A. Goesmann, A.-C. Hauschild, O. Schwengers, and D. Heider, "Prediction of antimicrobial resistance based on whole-genome sequencing and machine learning," *Bioinformatics*, vol. 38, no. 2, pp. 325–334, 2022.

- [5] P. Compeau and P. Pevzner, *Bioinformatics Algorithms: An Active Learning Approach*. Active Learning Publishers, 2014.
- [6] S. Haykin, *Neural Networks and Learning Machines*, 3rd ed. Pearson, 2009.
- [7] I. Goodfellow, Y. Bengio, and A. Courville, *Deep Learning*. MIT Press, 2016.
- [8] N. Srivastava, G. Hinton, A. Krizhevsky, I. Sutskever, and R. Salakhutdinov, "Dropout: A simple way to prevent neural networks from overfitting," *Journal of Machine Learning Research*, vol. 15, pp. 1929–1958, 2014.
- [9] I. Loshchilov and F. Hutter, "Decoupled weight decay regularization," in *International Conference on Learning Representations*, 2019, arXiv:1711.05101.
- [10] M. Schuster and K. K. Paliwal, "Bidirectional recurrent neural networks," *IEEE Transactions on Signal Processing*, vol. 45, no. 11, pp. 2673–2681, 1997.
- [11] K. Cho, B. van Merriënboer, C. Gulcehre, D. Bahdanau, F. Bougares, H. Schwenk, and Y. Bengio, "Learning phrase representations using rnn encoder–decoder for statistical machine translation," in *Proceedings of the 2014 Conference on Empirical Methods in Natural Language Processing*, 2014, pp. 1724–1734.
- [12] D. Bahdanau, K. Cho, and Y. Bengio, "Neural machine translation by jointly learning to align and translate," in *International Conference on Learning Representations*, 2015, arXiv:1409.0473.
- [13] L. Lugo and E. Barreto-Hernandez, "A recurrent neural network approach for whole genome bacteria identification," *Applied Artificial Intelligence*, vol. 35, no. 9, pp. 642–656, 2021.
- [14] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, L. Kaiser, and I. Polosukhin, "Attention is all you need," in *Advances in Neural Information Processing Systems*, vol. 30, 2017.
- [15] R. Pascanu, T. Mikolov, and Y. Bengio, "On the difficulty of training recurrent neural networks," in *Proceedings of the 30th International Conference on Machine Learning*, ser. Proceedings of Machine Learning Research, vol. 28, 2013, pp. 1310–1318.